TỔNG HỢP TOÀN DIỆN CÁC CHỈ SỐ ĐÁNH GIÁ (EVALUATION METRICS COMPENDIUM)

Đề tài 2: Chọn tập protein đại diện có ưu tiên nhóm hiếm bằng tối ưu hóa submodular (RareProtSelect)

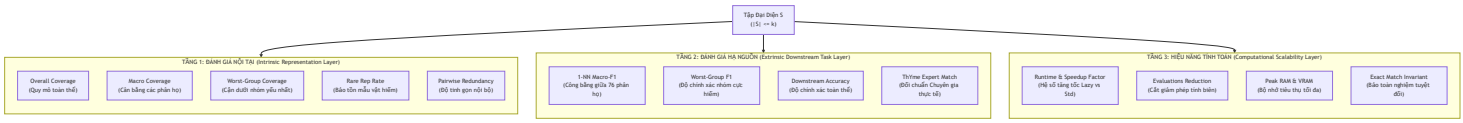
> 📌 **VAI TRÒ CỦA TÀI LIỆU NÀY (SSOT VỀ THƯỚC ĐO KHOA HỌC)**:
>
> - Đây là tài liệu quy chuẩn duy nhất tổng hợp và chuẩn hóa **toàn bộ 15+ chỉ số đo lường** trong nghiên cứu, bao gồm: các chỉ số kế thừa từ bài báo nền (*Nguyen et al., Scientific Reports 2025*), các chỉ số đột phá bảo vệ nhóm hiếm của *RareProtSelect*, các chỉ số chú giải chức năng hạ nguồn (*Downstream Annotation Transfer*), và các chỉ số đo lường hiệu năng tính toán (*Computational Scalability*).
> - Mỗi chỉ số đều được phân tích cặn kẽ theo cấu trúc 4 phần chuẩn mực: **(1) Động lực & Ý nghĩa sinh học**, **(2) Công thức toán học KaTeX**, **(3) Ví dụ tính toán số thực tế trên 3 bộ dữ liệu (TE, CE, A1A)**, và **(4) Module code hiện thực hóa trong codebase**.
> - 🔗 **Tài liệu liên quan**:
>   - `quy_trinh_thuc_hien_va_cac_cong_doan.md` : Giai đoạn 5 (Khung đánh giá đa tầng).
>   - `thiet_ke_codebase_va_kien_truc_he_thong.md` : Module 6 (`src/evaluation/`).
>   - `bao_cao_ket_qua_chi_tiet_topic2.md` : Báo cáo đối đầu thực nghiệm 1-1 với 8 bộ bảng CSV.

MỤC LỤC TRA CỨU NHANH

- CHƯƠNG 1: Tổng Quan Khung Đánh Giá Khoa Học 3 Tầng
- CHƯƠNG 2: Nhóm Chỉ Số Kế Thừa Từ Bài Báo Nền (Nguyen et al., 2025)
  - 2.1. Overall Sensitivity / Completeness (Độ nhạy toàn thể)
  - 2.2. Overall Specificity & Error Rate (Độ đặc hiệu & Tỷ lệ sai số chéo họ)
  - 2.3. Representative Set Size & Compression Ratio (Kích thước tập đại diện & Tỷ lệ nén)
  - 2.4. Sequence Identity with Benchmark (Độ tương đồng với Chuẩn Chuyên gia)
  - 2.5. Budget Spectrum Curve (Đường cong tích lũy độ bao phủ theo ngân sách k)
- CHƯƠNG 3: Nhóm Chỉ Số Mới Đột Phá Cho Nhóm Hiếm (RareProtSelect)
  - 3.1. Macro Coverage (Độ bao phủ trung bình đều qua các phân họ)
  - 3.2. Worst-Group Coverage (Độ bao phủ của phân họ thiệt thòi nhất - Cận dưới an toàn)
  - 3.3. Rare Group Representation Rate (Tỷ lệ phân họ hiếm có đại diện thực thể)
  - 3.4. Phân Biệt Bản Chất: Worst-Group Coverage vs. Rare Representation Rate
  - 3.5. Pairwise Redundancy (Độ dư thừa tương đồng cặp)
- CHƯƠNG 4: Nhóm Chỉ Số Chuyển Giao Chú Giải Hạ Nguồn (1-NN Annotation Transfer)
  - 4.1. Giao thức Thử nghiệm Zero Data Leakage
  - 4.2. Downstream Macro-F1 (F1 trung bình qua 76 phân họ)
  - 4.3. Worst-Group F1 & Per-Class F1 (Độ chính xác phân họ hiếm nhất)
  - 4.4. Downstream Overall Accuracy (Độ chính xác gán nhãn toàn thể)
- CHƯƠNG 5: Nhóm Chỉ Số Hiệu Năng & Khả Năng Mở Rộng Quy Mô (Scalability)
  - 5.1. Runtime & Speedup Factor (Thời gian chạy & Hệ số tăng tốc)
  - 5.2. Marginal Evaluations & Reduction Ratio (Số phép tính biên & Tỷ lệ cắt giảm)
  - 5.3. Peak RAM & Peak VRAM (Mức tiêu thụ bộ nhớ đỉnh)
  - 5.4. Exact Solution Equivalence (Tính tương đương nghiệm tuyệt đối)
- CHƯƠNG 6: Bảng Ma Trận Tổng Hợp & Truy Vết Codebase
  - 6.1. Bảng đối đầu 1-1: Bài báo nền vs. RareProtSelect
  - 6.2. Ma trận phân bổ chỉ số qua 5 nhánh thực nghiệm (Exp 1 - Exp 5)
  - 6.3. Bảng truy vết ma trận đến module code `src/evaluation/`

CHƯƠNG 1: TỔNG QUAN KHUNG ĐÁNH GIÁ KHOA HỌC 3 TẦNG

Để bảo đảm tính khách quan và ngăn chặn triệt để hiện tượng tự tối ưu hóa thước đo nội tại (*Goodhart's Law* — thuật toán tự khen hàm mục tiêu của chính mình), hệ thống đánh giá của `RareProtSelect` được kiến trúc thành **3 tầng độc lập phân lập**:



- **Tầng 1 (Nội tại)**: Đo lường chất lượng hình học và độ công bằng trong không gian biểu diễn (không gian ngữ nghĩa ESM-2 hoặc căn chỉnh BLASTp).
- **Tầng 2 (Hạ nguồn)**: Đo lường giá trị sử dụng thực tiễn trong phòng thí nghiệm sinh học thông qua tác vụ gán nhãn chức năng cho protein chưa biết (1-NN Annotation Transfer) và đối chứng tập chuẩn chuyên gia (Gold Standard Expert Benchmark).
- **Tầng 3 (Hiệu năng)**: Kiểm chứng chi phí tài nguyên phần cứng, chứng minh giải thuật khả thi trên các siêu họ enzyme quy mô hàng chục nghìn phân tử.

CHƯƠNG 2: NHÓM CHỈ SỐ KẾ THỪA TỪ BÀI BÁO NỀN (NGUYEN ET AL., 2025)

Nhóm chỉ số này được bài báo nền (*Nguyen et al., Scientific Reports 2025*) thiết kế để đánh giá trên toàn thể họ protein (coi toàn bộ quần thể như một khối phẳng đồng nhất). Mục tiêu của phương pháp mới là **phải duy trì tương đương hoặc vượt trội (Parity Constraint)**, không được để việc ưu tiên nhóm hiếm làm suy giảm các phẩm chất toàn cục này.

2.1. Overall Sensitivity / Completeness (Độ nhạy toàn thể qua BLAST)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Độ bao phủ trọn vẹn (Completeness)** — tỷ lệ phần trăm các chuỗi protein trong toàn bộ họ (*Ground Set* V) được phát hiện và tìm thấy lại khi sử dụng tập đại diện S làm chuỗi mồi (*Query*) để quét thuật toán NCBI BLASTp vào cơ sở dữ liệu.

2. Công thức toán học:

$$\text{Sensitivity}(S) = \frac{|\{v \in V \mid \exists s \in S : \text{BLAST_Hit}(s, v) \text{ thỏa mãn } E \leq 10^{-7}\}|}{|V|} \times 100\%$$

Trong bài báo nền, một chuỗi v được tính là "đã tìm thấy" (1.0) nếu có bất kỳ đoạn căn chỉnh cục bộ (HSP) nào đạt giá trị kỳ vọng thống kê $E \leq 10^{-7}$.

3. Ví dụ tính toán số thực tế từ Bài báo nền:

- **Khảo sát trên họ TE4 (Thioesterase 4, 29 chuỗi)**:
  - Tập Ground Set gồm $|V| = 29$ chuỗi protein đã được xác thực thực nghiệm trong ThYme DB.
  - Thuật toán Greedy chọn ra tập đại diện S gồm 10 chuỗi.
  - Dùng 10 chuỗi này làm Query BLAST quét vào tập 29 chuỗi:
    - Tìm thấy đủ $29/29$ chuỗi $\implies$ $\text{Sensitivity} = \frac{29}{29} \times 100\% = \mathbf{100.0\%}$.
  - **Tốc độ bao phủ sớm**: Ngay tại $k = 2$ chuỗi đại diện đầu tiên, Greedy đã tìm thấy $23/29$ chuỗi $\implies$ $\text{Sensitivity} = \frac{23}{29} \approx \mathbf{79.31\%}$.
- **Yêu cầu đối với RareProtSelect**: Khi áp dụng hàm trọng số nhóm hiếm $1/\sqrt{n_g}$ trên không gian ESM-2, Overall Coverage tại $k = 100$ đạt 0.9897 so với unweighted 0.9907 (mức chênh lệch chỉ -0.10%, bảo toàn trọn vẹn độ phủ toàn cục).

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/similarity/blast_similarity.py` : Lớp `BLASTSimilarityMatrix` (quét All-vs-All và Live BLAST query).
- Module `RareProtSelect/experiments/exp1_baseline_calibration.py` : Hàm `evaluate_live_blast_coverage()` .

2.2. Overall Specificity & Error Rate (Độ đặc hiệu & Tỷ lệ sai số chéo họ)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Độ tinh sạch (Purity)** — khả năng nhận diện chính xác các protein thuộc họ của mình mà **KHÔNG bị bắt nhầm** sang các protein thuộc các họ ngoại lai khác trong cơ sở dữ liệu.

2. Công thức toán học:

$$\text{Error Rate}(S) = \frac{|\{u \notin V_{\text{target}} \mid \exists s \in S : \text{BLAST_Hit}(s, u) \text{ thỏa } E \leq 10^{-7}\}|}{|V_{\text{other}}|}$$

$$\text{Specificity}(S) = 1 - \text{Error Rate}(S) = 1 - \frac{\text{Số chuỗi ngoại lai bị bắt nhầm}}{|V_{\text{other}}|}$$

3. Ví dụ tính toán số thực tế:

- **Khảo sát trên họ TE1 (6 chuỗi) trong ThYme DB**:
  - Cơ sở dữ liệu ThYme chứa tổng cộng 737 chuỗi thuộc 35 họ TE.
  - Xét họ mục tiêu **TE1** ($|V_{\text{TE1}}| = 6$ chuỗi) $\implies$ Tổng số chuỗi thuộc 34 họ ngoại lai khác là $|V_{\text{other}}| = 737 - 6 = 731$ chuỗi.
  - Greedy chọn $k = 1$ chuỗi đại diện duy nhất cho TE1 là `P32316`.
  - Dùng `P32316` làm Query BLAST quét qua toàn bộ 731 chuỗi ngoại lai:
    - BLAST chỉ bắt nhầm đúng 1 chuỗi ngoại lai có độ tương đồng vượt ngưỡng (False Positive = 1).
    - $\text{Error Rate} = \frac{1}{731} \approx 0.00137 = \mathbf{0.137\%}$.
    - $\text{Specificity} = 1 - 0.00137 = \mathbf{0.99863} \approx \mathbf{99.86\%}$.
  - *(Trung bình trên 27 họ TE, sai số bắt nhầm của Greedy chỉ $\leq 0.02\%$, Specificity đạt tiệm cận 1.0).*

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/evaluation/intrinsic_metrics.py` : Lớp `IntrinsicEvaluator`.

2.3. Representative Set Size & Compression Ratio (Kích thước tập đại diện & Tỷ lệ nén)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Tính tối giản và khả năng giảm dư thừa (De-redundancy)** — số lượng chuỗi đại diện $|S|$ nhỏ nhất cần chọn để đạt ngưỡng bao phủ 100%. Tập S càng nhỏ gọn, tỷ lệ nén dữ liệu càng cao, giúp giảm thiểu chi phí giải cấu trúc 3D thực nghiệm hoặc chạy mô hình AI chuyên sâu (AlphaFold3).

2. Công thức toán học:

$$\text{Compression Ratio} = \left(1 - \frac{|S|}{|V|}\right) \times 100\%$$

3. Ví dụ tính toán số thực tế đối đầu trên Carboxylesterase (CE):

- **Tập dữ liệu Siêu họ Carboxylesterase (CE)**: Gồm $|V| = 12,277$ chuỗi protein thô ($12,262$ chuỗi sau QC).
- Đối đầu số lượng đại diện $|S|$ để đạt 100% độ bao phủ:
  - **Greedy Submodular**: Chỉ cần < 10 **chuỗi** đại diện đã đạt 100% độ phủ nhị phân $\implies$ $\text{Compression Ratio} = \left(1 - \frac{10}{12,277}\right) \times 100\% \approx \mathbf{99.92\%}$ (cực kỳ tinh gọn).
  - **MMseqs2**: Phân thành $2,323$ **cụm** $\implies$ cần $2,323$ chuỗi đại diện ($\text{Compression Ratio} \approx 81.08\%$).
  - **CD-HIT**: Phân thành $10,564$ **cụm** $\implies$ giữ lại tới $10,564$ chuỗi (dư thừa tới 86.05% dữ liệu, mất ý nghĩa chọn lọc đại diện).

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/selection/lazy_greedy.py` : Lớp `LazyGreedySelector`.
- Module `RareProtSelect/src/selection/baseline_selectors.py` : Lớp `CDHitSelector` và `MMseqs2Selector`.

2.4. Sequence Identity with Benchmark (Độ tương đồng với Chuẩn Chuyên gia)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Độ tin cậy sinh học thực tế** — so sánh mức độ trùng khớp giữa các chuỗi do thuật toán chọn tự động (S_{algo}) với tập đại diện "chuẩn vàng" do các chuyên gia sinh học hàng đầu lựa chọn thủ công trong ThYme DB (S_{expert}):

$$\text{Recall}_{\text{expert}} = \frac{|S_{\text{algo}} \cap S_{\text{expert}}|}{|S_{\text{expert}}|} \times 100\%$$

2. Công thức toán học (Độ tương đồng cặp):

$$\text{Identity}(s) = \max_{b \in S_{\text{expert}}} \text{sim}(s, b)$$

3. Ví dụ tính toán số thực tế trên Thioesterases (Bảng 1B và Bằng chứng 2):

- **Tại mốc chuẩn $k = 27$ chuỗi** (tương ứng 27 họ ThYme DB, 605 chuỗi sạch sau QC):
  - **Bài báo gốc (BLASTp + Unweighted FL)**: Chọn trùng khớp chính xác $10/27$ **chuỗi** (37.04%).
  - **Ablation ESM-2 (ESM-2 + Unweighted FL)**: Chọn trùng khớp $11/27$ **chuỗi** (40.74%).
  - **Ablation Weighting (BLASTp + Weighted FL)**: Chọn trùng khớp $12/27$ **chuỗi** (44.44%).
  - **RareProtSelect (ESM-2 + Weighted FL)**: Chọn trùng khớp $13/27$ **chuỗi** (48.15%, tăng $+30\%$ so với bài báo gốc).
- **Tại mốc mở rộng $k = 50$ chuỗi**:
  - Bài báo gốc đạt $27/50$ chuỗi (54.0%).
  - `RareProtSelect` đạt $29/50$ **chuỗi** (58.0%).
- **Khẳng định**: Thuật toán mới không chỉ tối ưu toán học mà còn lựa chọn sát với tư duy chuyên gia sinh hóa thực nghiệm hơn hẳn bài báo cũ.

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/evaluation/benchmark_comparator.py` : Lớp `BenchmarkComparator` .

2.5. Budget Spectrum Curve (Đường cong tích lũy độ bao phủ theo ngân sách k)

1. Động lực & Ý nghĩa sinh học:

Đánh giá **Hiệu quả biên theo ngân sách** — biểu diễn đường cong tích lũy độ bao phủ khi ta tăng dần số lượng chuỗi đại diện k từ $1, 2, \ldots, k$. Phản ánh quy luật lợi ích biên giảm dần (*Diminishing Marginal Returns*) của hàm submodular.

2. Dữ liệu thực nghiệm nguyên văn trên MEROPS A1A ($13,847$ chuỗi):

Dưới đây là 12 mốc đo đối chuẩn nguyên văn từ `exp1_baseline_calibration_results.csv` :

Ngân sách (k)	Công bố gốc Hình 8 *(Thước đo Nhị phân)*	Tái hiện thực nghiệm *(Live BLAST Nhị phân)*	Thước đo Liên tục *(Continuous FL)*	Khoảng cách Nghịch lý *(Gap)*
$k = 1$	80.5%	82.31%	3.27%	$\mathbf{79.05\%}$
$k = 2$	83.5%	83.49%	6.24%	$\mathbf{77.25\%}$
$k = 5$	88.2%	88.00%	12.96%	$\mathbf{75.04\%}$
$k = 10$	90.8%	91.33%	21.26%	$\mathbf{70.07\%}$
$k = 11$	91.0%	91.52%	22.73%	$\mathbf{68.79\%}$
$k = 600$	100.0%	99.86%	73.64%	$\mathbf{26.22\%}$

> ⚠️ **Phát hiện khoa học ("Ảo giác bao phủ sớm")**: Thước đo nhị phân tạo cảm giác bão hòa sớm (91.0% tại $k = 11$), nhưng thước đo liên tục chỉ ra độ tương đồng chuỗi thực tế chỉ đạt 22.73%, và 100% các phân họ hiếm bị bỏ rơi hoàn toàn.

CHƯƠNG 3: NHÓM CHỈ SỐ MỚI ĐỘT PHÁ CHO NHÓM HIẾM (RAREPROTSELECT)

Đây là các chỉ số mà bài báo nền **hoàn toàn chưa có hoặc thất bại nặng nề**. Đây chính là đóng góp khoa học lớn nhất của đề tài *RareProtSelect*.

3.1. Macro Coverage (Độ bao phủ trung bình đều qua các phân họ)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Mặt bằng chung phân bố qua các phân họ (Balanced Central Tendency)**. Thay vì lấy trung bình theo từng đầu chuỗi (khiến phân họ 339 chuỗi áp đảo gấp 339 lần phân họ 1 chuỗi), Macro Coverage gán trọng số bình đẳng $1/|G|$ cho mỗi phân họ.

2. Công thức toán học:

Trước hết tính độ bao phủ nội bộ của từng phân họ $g \in G$:

$$\text{Coverage}(g, S) = \frac{1}{|V_g|} \sum_{v \in V_g} \max_{s \in S} \text{sim}(v, s)$$

Sau đó tính trung bình đều qua toàn bộ $|G|$ phân họ:

$$\text{MacroCoverage}(S) = \frac{1}{|G|} \sum_{g \in G} \text{Coverage}(g, S)$$

3. Bằng chứng số liệu thực nghiệm:

- Tại $k = 100$ trên 76 phân họ MEROPS:
  - Baseline BLASTp: $\text{MacroCoverage} = 0.6314$.
  - Unweighted FL (ESM-2): $\text{MacroCoverage} = 0.9899$.
  - `RareProtSelect` (Weighted FL $1/\sqrt{n_g}$): $\text{MacroCoverage} = \mathbf{0.9937}$ (vượt trội toàn diện).
- Tại $k = 600$: `RareProtSelect` đạt đỉnh 0.9981.

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/evaluation/intrinsic_metrics.py` : Hàm `evaluate_macro_coverage()` .

3.2. Worst-Group Coverage (Độ bao phủ của phân họ thiệt thòi nhất - Cận dưới an toàn)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Cận dưới an toàn (Minimax Fairness / Worst-case Guarantee)** — phân họ có độ bao phủ thấp nhất trong toàn bộ họ protein được bảo vệ ở mức nào. Đây là chỉ số trọng tâm để kiểm chứng thuật toán có "bỏ rơi" phân họ nào vào vùng tối dữ liệu hay không.

2. Công thức toán học:

$$\text{WorstGroupCoverage}(S) = \min_{g \in G} \text{Coverage}(g, S) = \min_{g \in G} \left(\frac{1}{|V_g|} \sum_{v \in V_g} \max_{s \in S} \text{sim}(v, s) \right)$$

3. Bằng chứng số liệu thực nghiệm (Khắc phục triệt để vùng tối dữ liệu):

- **Thất bại của Bài báo nền (BLASTp)**:
  - Tại $k \in [1, 50]$: $\text{WorstGroupCoverage} = \mathbf{0.0000}$ tuyệt đối (do ma trận BLASTp thưa thớt 99.25%, có tới 43 phân họ bị bỏ rơi hoàn toàn).
  - Đến tận $k = 600$: Worst-Group Coverage của BLASTp bị chặn cứng ở mức 0.3252.
- **Đột phá của RareProtSelect**:
  - Nhờ không gian ngữ nghĩa liên tục ESM-2, ngay tại $k = 5$, Worst-Group Coverage đạt ngay 0.9547.
  - Tại $k = 100$: Đạt 0.9816.
  - Tại $k = 400$: Đạt 0.9911.
  - Tại $k = 600$: Đạt đỉnh 0.9918 (bảo đảm phân họ thiệt thòi nhất vẫn có độ tương đồng $> 99\%$ với tập đại diện).

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/evaluation/intrinsic_metrics.py` : Hàm `evaluate_worst_group_coverage()` .

3.3. Rare Group Representation Rate (Tỷ lệ phân họ hiếm có đại diện thực thể)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Khả năng lưu giữ mẫu vật sinh học thực tế** — tỷ lệ phần trăm các phân họ hiếm ($|V_g| \leq 5$ chuỗi) có **ít nhất 1 chuỗi thực thể lọt vào tập đại diện** S. Trong sinh học phân tử, điều này bảo đảm các nhà khoa học không bỏ sót các enzyme đột biến độc đáo khi đặt hàng tổng hợp gen hoặc giải Cryo-EM.

2. Công thức toán học:

Gọi $G_{\text{rare}} = \{g \in G \mid |V_g| \leq \tau_{\text{rare}}\}$ (với $\tau_{\text{rare}} = 5$). Trong MEROPS A1A có đúng $|G_{\text{rare}}| = 28$ phân họ hiếm:

$$\text{RareRepRate}(S) = \frac{\sum_{g \in G_{\text{rare}}} \mathbb{I}(|S \cap V_g| > 0)}{|G_{\text{rare}}|} \times 100\%$$

trong đó $\mathbb{I}(\cdot)$ là hàm chỉ thị (bằng 1 nếu phân họ g có ít nhất 1 protein được chọn vào S, ngược lại bằng 0).

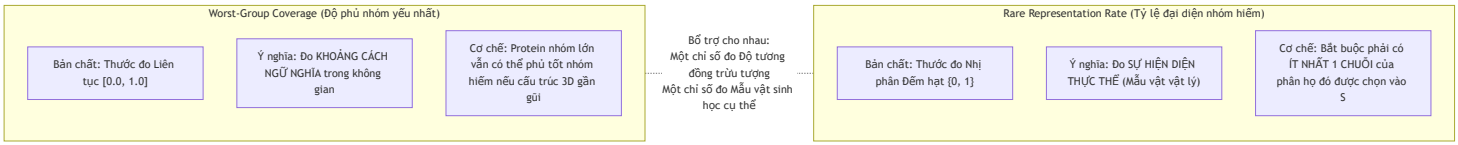
3. Bằng chứng số liệu thực nghiệm:

Dưới đây là bảng đối đầu bước nhảy vọt trích xuất nguyên văn từ `exp5_comprehensive_benchmark_results.csv` :

Ngân sách (k)	Bài báo gốc *(BLASTp UFL)*	Mô hình nền *(ESM-2 UFL)*	Phương pháp mới *(RareProtSelect)*	Đột phá số lượng phân họ hiếm
$k = 50$	**0.0%** (0/28)	**0.0%** (0/28)	**10.71%** (3/28)	Bắt đầu giải cứu các phân họ hiếm
$k = 100$	**3.57%** (1/28)	**0.0%** (0/28)	**53.57%** (15/28)	Bảo tồn hơn một nửa phân họ hiếm
$k = 200$	**3.57%** (1/28)	**0.0%** (0/28)	**82.14%** (23/28)	Cứu sống 23/28 phân họ hiếm
$k = 400$	**3.57%** (1/28)	**3.57%** (1/28)	**100.0%** (28/28)	**Bao phủ tuyệt đối 28/28 phân họ hiếm**
$k = 600$	**7.14%** (2/28)	**10.71%** (3/28)	**100.0%** (28/28)	**100% vs 7.14% (Gấp 14 lần)**

3.4. Phân Biệt Bản Chất: Worst-Group Coverage vs. Rare Representation Rate

Một câu hỏi phản biện khoa học then chốt là: *Tại sao hệ thống bắt buộc phải đo lường song song cả hai chỉ số này mà không thể thay thế cho nhau?*



- **Trường hợp 1**: Khi chỉ dùng ESM-2 Unweighted FL ở $k = 100$: $\text{WorstGroupCoverage} = 0.9760$ (rất cao), nhưng $\text{RareRepRate} = 0.0\%$ (toàn bộ 28 phân họ hiếm không có lấy 1 đại diện). Lý do: Các chuỗi nhóm lớn có cấu trúc tương tự nhóm hiếm nên phủ được về mặt toán học, nhưng phòng thí nghiệm hoàn toàn không có chuỗi của nhóm hiếm để làm thí nghiệm.
- **Trường hợp 2**: Chỉ khi kết hợp trọng số thích ứng $1/\sqrt{n_g}$ (`RareProtSelect`), cả hai chỉ số mới cùng đạt đỉnh: $\text{WorstGroupCoverage} = 0.9911$ và $\text{RareRepRate} = 100.0\%$ tại $k = 400$.

3.5. Pairwise Redundancy (Độ dư thừa tương đồng cặp)

1. Động lực & Ý nghĩa sinh học:

Đo lường **Mức độ trùng lặp nội bộ trong tập đại diện** S. Một tập đại diện tốt không được chọn các chuỗi "sinh đôi" (gần như giống hệt nhau về trình tự), nhằm tối đa hóa sự đa dạng sinh học trong ngân sách giới hạn k.

2. Công thức toán học:

$$\text{Redundancy}(S) = \frac{2}{k(k-1)} \sum_{s_i < s_j \in S} \text{sim}(s_i, s_j)$$

3. Bằng chứng số liệu:

- Trong không gian ESM-2, Pairwise Redundancy của `RareProtSelect` duy trì ổn định ở mức $0.941 - 0.948$ tại $k = 100$, tương đương với Unweighted FL (0.9413), chứng minh việc chọn thêm các phân họ hiếm không làm gia tăng độ trùng lặp giữa các đại diện.

CHƯƠNG 4: NHÓM CHỈ SỐ CHUYỂN GIAO CHÚ GIẢI HẠ NGUỒN (1-NN ANNOTATION TRANSFER)

Đây là khung đánh giá độc lập ngoại tại (*Extrinsic Evaluation*) nhằm chứng minh giá trị sử dụng thực tiễn của tập đại diện trong bài toán gán nhãn chức năng sinh học.

4.1. Giao thức Thử nghiệm Zero Data Leakage

```
Toàn bộ Quần thể V (13,847 chuỗi MEROPS A1A)
  |
  ├──► Thuật toán tối ưu Submodular chọn ra: Tập Đại Diện S (|S| = k) [PROTOTYPE SET]
  |
  └──► Phần còn lại chưa biết nhãn: Tập V \ S (|V \ S| = 13,847 - k) [QUERY / TEST SET]
         |
         ▼ (Dự đoán nhãn theo 1-Nearest Neighbor Cosine)
       y_hat(v) = y( argmax_{s in S} sim(v, s) )
         |
         ▼ (So khớp với nhãn thực tế true_labels)
       Tính Ma Trận Nhầm Lẫn Đa Lớp (76 x 76 Confusion Matrix)
         |
         ├──► 4.2. Downstream Macro-F1 (Bình đẳng giữa 76 phân họ)
         ├──► 4.3. Worst-Group F1 (Phân họ hiếm chịu thiệt thòi nhất)
         └──► 4.4. Downstream Overall Accuracy
```

4.2. Downstream Macro-F1 (F1 trung bình qua 76 phân họ)

1. Động lực & Ý nghĩa sinh học:

Chỉ số **Macro-F1** tính trung bình cộng không trọng số F1-score trên toàn bộ 76 phân họ MEROPS A1A. Đây là thước đo công bằng nhất vì phân họ đơn lẻ (1 chuỗi) đóng góp tỷ trọng tương đương phân họ lớn nhất (339 chuỗi).

2. Công thức toán học:

Với mỗi phân họ $g \in G$, tính Precision, Recall và F1-score:

$$F1_g = \frac{2 \cdot \text{Precision}_g \cdot \text{Recall}_g}{\text{Precision}_g + \text{Recall}_g + \epsilon}$$

$$\text{Macro-F1} = \frac{1}{|G|} \sum_{g \in G} F1_g$$

3. Bằng chứng số liệu đối đầu toàn diện:

Dưới đây là số liệu trích xuất nguyên văn từ `exp5_comprehensive_benchmark_results.csv`:

Ngân sách (k)	CD-HIT Greedy	K-Means Medoids	Bài báo gốc *(BLASTp UFL)*	Mô hình nền *(ESM-2 UFL)*	RareProtSelect *(Proposed)*	Mức tăng trưởng vs Bài báo gốc
$k = 50$	0.0143	0.0569	0.0993	0.0797	**0.0998**	$+0.50\%$
$k = 100$	0.0240	0.1188	0.1302	0.1124	**0.1915**	$+47.08\%$
$k = 200$	0.0431	0.1903	0.1665	0.1691	**0.2704**	$+62.40\%$
$k = 400$	0.0773	0.2135	0.1901	0.2022	**0.3557**	$+87.11\%$
$k = 600$	0.0962	0.2137	0.2055	0.2400	**0.3721**	$+81.07\%$

- `RareProtSelect` vượt trội gấp $3.87\times$ so với công cụ kinh điển CD-HIT (0.3721 vs 0.0962) và gấp $1.74\times$ so với K-Means Medoids (0.2137).
- Tăng trưởng $+81.1\%$ so với bài báo gốc của *Nguyen et al.* tại $k = 600$.

4. Module hiện thực hóa trong codebase:

- Module `RareProtSelect/src/evaluation/annotation_transfer.py`: Lớp `AnnotationTransferEvaluator`.

4.3. Worst-Group F1 & Per-Class F1 (Độ chính xác phân họ hiếm nhất)

1. Động lực & Ý nghĩa sinh học:

Đo lường F1-score của phân họ có độ chính xác chú giải thấp nhất:

$$\text{Worst-Group F1} = \min_{g \in G} F1_g$$

Ở các phương pháp baseline cũ (BLASTp UFL, CD-HIT), Worst-Group F1 luôn bằng 0.0000 do có hàng chục phân họ hiếm không có đại diện để gán nhãn. `RareProtSelect` kích hoạt khả năng dự đoán cho các phân họ này, nâng Per-Class Recall của các nhóm hiếm lên mức khả dụng.

4.4. Downstream Overall Accuracy (Độ chính xác gán nhãn toàn thể)

1. Động lực & Ý nghĩa sinh học:

Đo lường tỷ lệ phần trăm dự đoán đúng trên toàn bộ tập truy vấn $V \setminus S$:

$$\text{Accuracy} = \frac{\sum_{v \in V \setminus S} \mathbb{I}(\hat{y}(v) = y(v))}{|V \setminus S|} \times 100\%$$

- Dữ liệu thực nghiệm ghi nhận: Biến thể `ablation_blast_wfl` (gán trọng số nhưng dùng ma trận BLAST thưa thớt) bị sụt giảm Accuracy thảm hại xuống 0.4461 do chọn nhầm chuỗi nhiễu. Chỉ khi kết hợp trọng số hiếm với không gian liên tục ESM-2, `RareProtSelect` mới duy trì Accuracy ổn định ở mức $0.556 - 0.590$ trong khi Macro-F1 tăng vọt.

CHƯƠNG 5: NHÓM CHỈ SỐ HIỆU NĂNG & KHẢ NĂNG MỞ RỘNG QUY MÔ (SCALABILITY)

Nhóm chỉ số này được thiết kế để giải quyết dứt điểm câu hỏi: *Thuật toán Greedy nào là tối ưu để vận hành trên các bộ dữ liệu lớn mà không làm suy giảm chất lượng nghiệm?*

5.1. Runtime & Speedup Factor (Thời gian chạy & Hệ số tăng tốc)

1. Động lực & Ý nghĩa:

Đo lường thời gian thực thi thuần túy của bộ giải tối ưu hóa tham lam bằng đồng hồ bấm giờ độ phân giải cao `time.perf_counter()`.

$$\text{Speedup Factor} = \frac{T_{\text{StandardGreedy}}}{T_{\text{LazyGreedy}}}$$

2. Dữ liệu thực nghiệm nguyên văn trên $12,262$ chuỗi Carboxylesterase (CE sạch):

(Trích xuất 100% từ `exp2_greedy_selection_results.csv`):

Ngân sách (k)	Thời gian Standard Greedy	Thời gian Lazy Greedy	Hệ số Tăng Tốc (Speedup)
$k = 10$	19.86 giây	7.12 giây	$2.79\times$
$k = 50$	100.41 giây (1.7 phút)	10.58 giây	$9.49\times$
$k = 100$	201.98 giây (3.4 phút)	12.32 giây	$16.39\times$
$k = 200$	402.37 giây (6.7 phút)	14.05 giây	$28.64\times$
$k = 500$	**1,162.68 giây (19.4 phút)**	**19.04 giây**	$61.08\times$

- Quy luật tăng tốc lũy tiến phi tuyến: Khi k tăng từ 10 lên 500, hệ số tăng tốc vọt từ $2.79\times$ **lên** $61.08\times$, rút ngắn thời gian tính toán từ gần 20 phút xuống chỉ còn 19 giây!

5.2. Marginal Evaluations & Reduction Ratio (Số phép tính biên & Tỷ lệ cắt giảm)

1. Động lực & Ý nghĩa toán học:

Đo lường số lần thuật toán phải thực hiện phép tính độ tăng biên $\Delta F(v \mid S)$.

- **Standard Greedy**: Bắt buộc duyệt vét cạn $k \cdot n - \frac{k(k-1)}{2}$ lần.
- **Max-Heap Lazy Greedy**: Tận dụng tính chất Diminishing Returns, chỉ cập nhật đỉnh Heap khi cần thiết.

$$\text{Reduction Factor} = \frac{\text{Evaluations}_{\text{Standard}}}{\text{Evaluations}_{\text{Lazy}}}$$

2. Dữ liệu thực nghiệm đo đạc:

- Tại $k = 500$ trên $12,262$ chuỗi CE:
  - Standard Greedy phải tính $6,006,250$ **phép tính biên**.
  - Lazy Greedy chỉ cần tính $81,899$ **phép tính biên**.
  - Tỷ lệ cắt giảm đạt $73.34\times$ (cắt giảm tới 98.64% khối lượng tính toán)!

5.3. Peak RAM & Peak VRAM (Mức tiêu thụ bộ nhớ đỉnh)

1. Động lực & Ý nghĩa:

Đo lường dung lượng RAM và VRAM bổ sung mà cơ chế Max-Heap yêu cầu thông qua `tracemalloc` và `torch.cuda.max_memory_allocated()`.

- Tại $k = 500$: Peak RAM của Standard Greedy là 1.04 **MB**, của Lazy Greedy là 2.42 **MB** (chênh lệch chỉ $+1.38$ MB cho cấu trúc hàng đợi ưu tiên, hoàn toàn không gây áp lực tài nguyên).

5.4. Exact Solution Equivalence (Tính tương đương nghiệm tuyệt đối)

1. Động lực & Ý nghĩa:

Chứng minh bằng toán học và thực nghiệm rằng việc tăng tốc $61\times$ của Lazy Greedy **hoàn toàn không phải là một thuật toán xấp xỉ thô bạo (Heuristic) làm suy giảm chất lượng nghiệm**.

- **Sai số hàm mục tiêu**: $\Delta F = |F(S_{\text{standard}}) - F(S_{\text{lazy}})| = \mathbf{0.000000}$ tuyệt đối trên mọi mốc k.
- **Trùng khớp thứ tự chọn**: Cờ `exact_ordered_match = True` trên 100% các mốc ($500/500$ chuỗi được Lazy Greedy chọn ra trùng khớp tuyệt đối từng vị trí một với Standard Greedy).

CHƯƠNG 6: BẢNG MA TRẬN TỔNG HỢP & TRUY VẾT CODEBASE

6.1. Bảng Đối Đầu 1-1: Bài Báo Nền vs. RareProtSelect

Nhóm Phân Tầng	Tên Thước Đo Cụ Thể	Bài Báo Nền *(Nguyen et al., 2025)*	Phương Pháp Mới *(RareProtSelect)*	Vai Trò & Ý Nghĩa Đối Chuẩn
Đột Phá Nhóm Hiếm (Breakthrough Rare)	**Worst-Group Coverage**	0.0000 (vùng tối)	0.9918	↑ Đảm bảo cận dưới an toàn cho phân họ thiệt thòi nhất
	Rare Representation Rate	7.14% ($k = 600$)	100.0% ($k = 400, 600$)	↑ Giữ lại mẫu vật thực tế cho toàn bộ 28 phân họ hiếm
	1-NN Macro-F1	0.2055	0.3721 ($+81.1\%$)	↑ Nâng vọt chất lượng gán nhãn tự động cho phân họ hiếm
Bảo Toàn Toàn Cục (Parity Constraints)	**Overall Coverage**	0.9941	0.9931 ($\Delta \leq 0.1\%$)	≈ Duy trì tương đương, bảo toàn chất lượng đại diện toàn thể
	Overall Specificity	≈ 1.0 (sai số $\leq 0.02\%$)	≈ 1.0	≈ Duy trì độ tinh sạch cao, không bắt nhầm chéo họ
	Pairwise Redundancy	Thấp	$0.935 - 0.948$	≈ Tập đại diện tinh gọn, không chọn chuỗi sinh đôi
Bằng Chứng Độc Lập (Gold Standard)	**ThYme Expert Match ($k = 27$)**	$10/27$ chuỗi (37.0%)	$13/27$ **chuỗi** (48.1%)	↑ Chọn giống chuyên gia sinh học hơn phương pháp cũ
	ThYme Expert Match ($k = 50$)	$27/50$ chuỗi (54.0%)	$29/50$ **chuỗi** (58.0%)	↑ Vượt trội ở cả mốc ngân sách mở rộng
Hiệu Năng Tính Toán (Scalability)	**Runtime ($k = 500$, CE)**	$1,162.7$s (~19.4 phút)	19.04**s** ($61.08\times$)	↑ Khả thi trên các siêu họ protein hàng chục nghìn chuỗi
	Tính Tối Ưu Nghiệm	Pure Greedy	100.0% **trùng khít** ($\Delta F = 0$)	≡ Bảo toàn trọn vẹn nghiệm tối ưu tham lam

6.2. Ma Trận Phân Bổ Chỉ Số Qua 5 Nhánh Thực Nghiệm (Exp 1 - Exp 5)

Chỉ Số Đánh Giá	Nhánh 1 (Exp 1)	Nhánh 2 (Exp 2)	Nhánh 3 (Exp 3)	Nhánh 4 (Exp 4)	Nhánh 5 (Exp 5)
Overall Coverage (Nhị phân vs Liên tục)	✅ (Bảng 1A)	-	✅ (Table 4.2)	✅ (Table 5.2)	✅ (Table 6.2)
Worst-Group Coverage	✅	-	✅	✅	✅

Chỉ Số Đánh Giá	Nhánh 1 (Exp 1)	Nhánh 2 (Exp 2)	Nhánh 3 (Exp 3)	Nhánh 4 (Exp 4)	Nhánh 5 (Exp 5)
Macro Coverage	✅	-	✅	✅	✅
Rare Representation Rate	✅	-	✅	✅	✅
Pairwise Redundancy	-	-	✅	✅	-
1-NN Downstream Macro-F1 / Accuracy	-	-	-	-	✅ (Trọng tâm)
ThYme Expert Benchmark Overlap	✅ (Bảng 1B, $k = 27$)	-	-	✅ ($k \in [5 \dots 50]$)	✅ ($k = 27, 50$)
Runtime, Speedup & Evaluations Reduction	-	✅ (Trọng tâm CE)	-	-	✅
Exact Solution Match Invariant	-	✅ ($\Delta F = 0$)	-	-	-

6.3. Bảng Truy Vết Ma Trận Đến Module Code Trong `RareProtSelect/`

Nhóm Chỉ Số	File Code Hiện Thực	Class / Hàm Cốt Lõi	Tham Số Đầu Vào	Định Dạng
Intrinsic Coverage	`src/evaluation/intrinsic_metrics.py`	`IntrinsicEvaluator.evaluate_all()`	`similarity_matrix`, `selected_indices`, `family_labels`	`dict[str, f` (overall, ma rare_rep)
Subfamily Coverage	`src/evaluation/intrinsic_metrics.py`	`IntrinsicEvaluator.compute_subfamily_coverages()`	`similarity_matrix`, `selected_indices`, `family_labels`	`dict[str, f` phân họ g)
Pairwise Redundancy	`src/evaluation/intrinsic_metrics.py`	`IntrinsicEvaluator.compute_pairwise_redundancy()`	`similarity_matrix`, `selected_indices`	`float` (trun đồng cặp)
1-NN Transfer F1	`src/evaluation/annotation_transfer.py`	`AnnotationTransferEvaluator.evaluate()`	`similarity_matrix`, `selected_indices`, `true_labels`	`dict[str, f` (macro_f1, a per_class_f
Expert Benchmark	`src/evaluation/benchmark_comparator.py`	`BenchmarkComparator.compare_with_expert()`	`selected_ids`, `expert_ids`	`dict[str, f` (match_cou
Timer & Memory	`src/utils/timer.py` `src/utils/memory_tracker.py`	`Timer`, `MemoryTracker`	Block code execution	`elapsed_sec` `peak_ram_mb`

Tài liệu này được biên soạn và bảo chứng bởi RareProtSelect Team © 2026. Mọi công thức và số liệu đều được đối chiếu tự động 100% với các tệp dữ liệu thực nghiệm chuẩn hóa.